# decition_tree.R

SANGHOOJEFFREY

Thu Jun 28 01:30:34 2018

```
# 분류함수로 logistic regression 외 다른 기계학습방법(데이터마이닝, 빅데이터방법)이 존재

# 1. 의사결정나무 (Decision Tree)
# 의사결정나무는 지니 불순도(Gini Impurity) 또는 정보이득 (Information Gain) 등의 기준을 사용하여
# 노드를 재귀적으로 분할하면서 나무 모형을 만든다.

# example
if(!require(rpart)) install.packages("rpart"); library(rpart)
```

```
## Loading required package: rpart
```

```
data(iris)
dt <- rpart(Species ~., data=iris)
table(iris$Species)
```

```
##
##     setosa versicolor  virginica
##         50         50         50
```

```
dt
```

```
## n= 150
##
## node), split, n, loss, yval, (yprob)
##       * denotes terminal node
##
## 1) root 150 100 setosa (0.33333333 0.33333333 0.33333333)
##   2) Petal.Length< 2.45 50   0 setosa (1.00000000 0.00000000 0.00000000) *
##   3) Petal.Length>=2.45 100  50 versicolor (0.00000000 0.50000000 0.500000
00)
##     6) Petal.Width< 1.75 54   5 versicolor (0.00000000 0.90740741 0.092592
59) *
##     7) Petal.Width>=1.75 46   1 virginica (0.00000000 0.02173913 0.9782608
7) *
```

```
# 총 150 개의 자료이며 기본적으로 각 종의 비율을 1/3, 1/3, 1/3
# 2) 기준에 의해 즉 Petal.Length<2.45 로 setosa 가 판별됨
# setosa 50 개 분류
# 6) Petal.width <1.75 를 기준으로 54 개의 versicolor 라 분류 (분류가 잘못된 자료
5 개)
# 7) 로 verginica 46 개 예측 (분류가 잘못된 자료 1 개)

# plot(dt)
plot(dt, compress=TRUE, margin=.2)
# compress 로 나무를 좀 더 조밀하게 그릴 수 있다.

text(dt, cex=0.9)
```

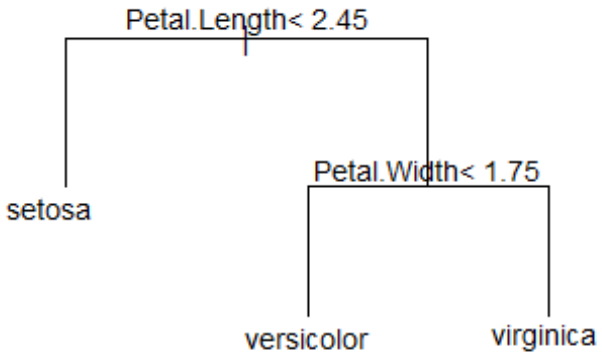


```
# cex 는 글자의 크기를 의미

pred.dt<-predict(dt, newdat=iris, type="class")

xtabs(~pred.dt+iris$Species)

##             iris$Species
## pred.dt      setosa versicolor virginica
##   setosa         50          0         0
```

```
##   versicolor      0         49         5
##   virginica       0          1        45

# Petal.Length<2.45, Petal.width<1.75 가 노드(Node)
# 노드 수 결정
# 가지치기 : 오분류 가능성이 높아지는 경우 노드를 정지
# 언제까지 나무모형을 성장시킬 것이냐?
# 너무 큰 나무는 자료를 과대적합하고, 반대로 너무 작은 나무는 자료를 과소 적합
# 일반적으로 사용되는 방법은 마디에 속하는 자료가 일정 수 이하일 때 분할 정시 (thum
b rule)

# another package
library(MASS)
if(!require(tree)) install.packages("tree");library(tree)

## Loading required package: tree

## Warning: package 'tree' was built under R version 3.4.4

tree.iris <- tree(Species ~., data=iris)
summary(tree.iris)

##
## Classification tree:
## tree(formula = Species ~ ., data = iris)
## Variables actually used in tree construction:
## [1] "Petal.Length" "Petal.Width"  "Sepal.Length"
## Number of terminal nodes:  6
## Residual mean deviance:  0.1253 = 18.05 / 144
## Misclassification error rate: 0.02667 = 4 / 150

plot(tree.iris)
text(tree.iris, cex=0.9)
```

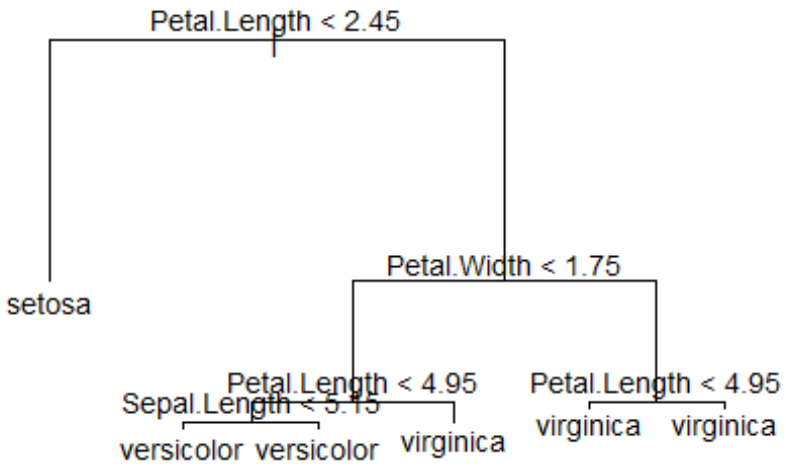


```
# 과적합화의 문제가 있으므로 가지치기단계가 필요함

cv.tree.out<-cv.tree(tree.iris,FUN=prune.tree, K = 5 )
plot(cv.tree.out)
```

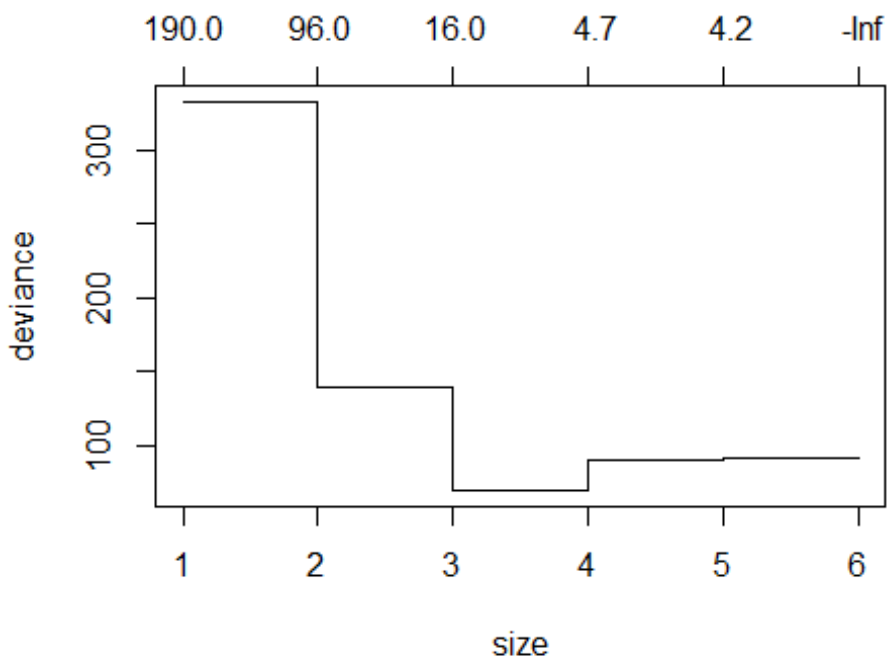


```
tree.iris2<-prune.tree(tree.iris, best=4)
plot(tree.iris2)
text(tree.iris2, cex=0.9)

# 의사결정나무의 장단점
# 장점 : 설명력이 높다.
#        결과에 대한 근거를 나무가지 형태로 쉽게 추적할 수 있다.
#        계산이 빠르고 변수 선택 능력이 있다.

# 단점 : 반응변수가 연속형일 때 사용하기 어렵다.
#        설명변수가 연속형일 때 낮은 예측능력을 보일 수 있다.
#        자료가 추가되면 나무구조가 바뀔 수 있다.
#        비선형데이터는 나무모형으로 잘 설명되지 않는다.

# 조건부 추론 나무는 조건부 분포로 분류하는 방법으로 과적합의 문제를 해결해준다.

if(!require(party)) install.packages("party"); library(party)

## Loading required package: party

## Warning: package 'party' was built under R version 3.4.4
```

```
## Loading required package: grid

## Loading required package: mvtnorm

## Warning: package 'mvtnorm' was built under R version 3.4.3

## Loading required package: modeltools

## Loading required package: stats4

## Loading required package: strucchange

## Loading required package: zoo

## Warning: package 'zoo' was built under R version 3.4.4

##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##     as.Date, as.Date.numeric

## Loading required package: sandwich
```

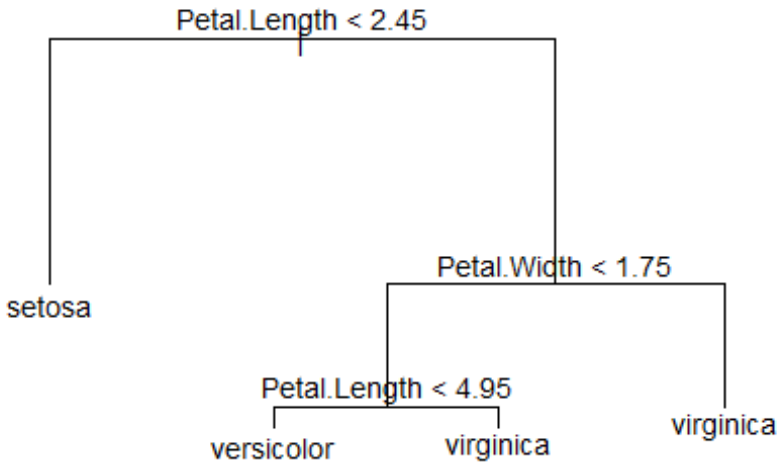


```
ct <- ctree(Species~., data=iris)
ct
```

```
##
##   Conditional inference tree with 4 terminal nodes
##
## Response:  Species
## Inputs:  Sepal.Length, Sepal.Width, Petal.Length, Petal.Width
## Number of observations:  150
##
## 1) Petal.Length <= 1.9; criterion = 1, statistic = 140.264
##   2)*  weights = 50
## 1) Petal.Length > 1.9
##   3) Petal.Width <= 1.7; criterion = 1, statistic = 67.894
##     4) Petal.Length <= 4.8; criterion = 0.999, statistic = 13.865
##       5)*  weights = 46
##     4) Petal.Length > 4.8
##       6)*  weights = 8
##   3) Petal.Width > 1.7
##     7)*  weights = 46
```

```
plot(ct)
```

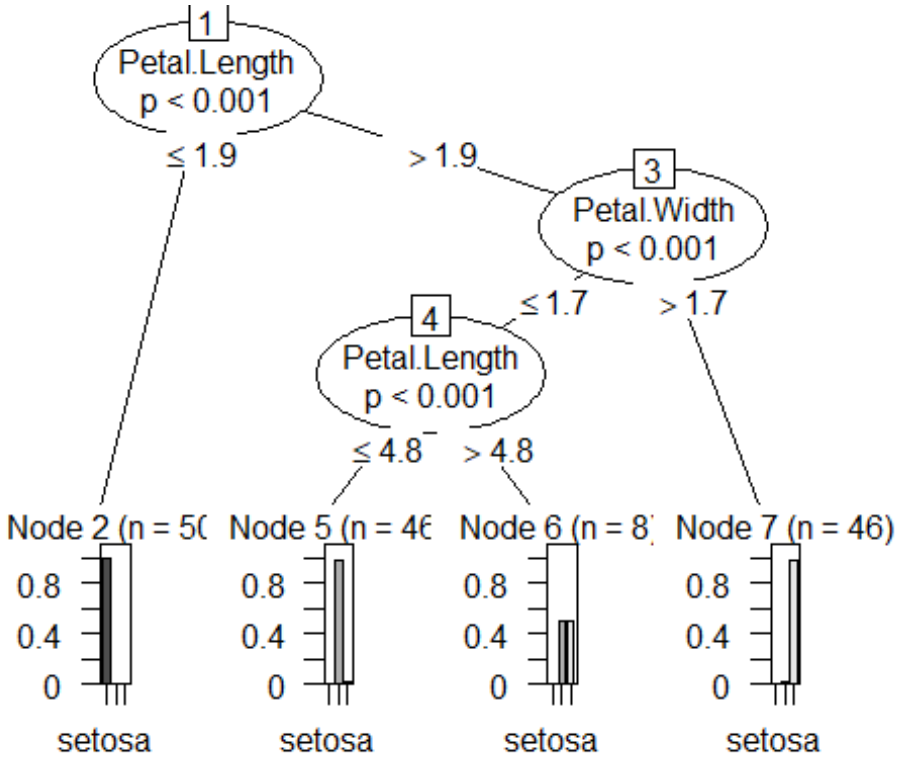


```
predict(ct, newdata=iris)
```

```
##   [1] setosa     setosa     setosa     setosa     setosa     setosa
##   [7] setosa     setosa     setosa     setosa     setosa     setosa
##  [13] setosa     setosa     setosa     setosa     setosa     setosa
##  [19] setosa     setosa     setosa     setosa     setosa     setosa
```

```
##  [25] setosa     setosa     setosa     setosa     setosa     setosa
##  [31] setosa     setosa     setosa     setosa     setosa     setosa
##  [37] setosa     setosa     setosa     setosa     setosa     setosa
##  [43] setosa     setosa     setosa     setosa     setosa     setosa
##  [49] setosa     setosa     versicolor versicolor versicolor versicolor
##  [55] versicolor versicolor versicolor versicolor versicolor versicolor
##  [61] versicolor versicolor versicolor versicolor versicolor versicolor
##  [67] versicolor versicolor versicolor versicolor virginica  versicolor
##  [73] versicolor versicolor versicolor versicolor versicolor versicolor
##  [79] versicolor versicolor versicolor versicolor versicolor versicolor
##  [85] versicolor versicolor versicolor versicolor versicolor versicolor
##  [91] versicolor versicolor versicolor versicolor versicolor versicolor
##  [97] versicolor versicolor versicolor versicolor virginica  virginica
## [103] virginica  virginica  virginica  virginica  versicolor virginica
## [109] virginica  virginica  virginica  virginica  virginica  virginica
## [115] virginica  virginica  virginica  virginica  virginica  versicolor
## [121] virginica  virginica  virginica  virginica  virginica  virginica
## [127] virginica  virginica  virginica  versicolor virginica  virginica
## [133] virginica  versicolor versicolor virginica  virginica  virginica
## [139] virginica  virginica  virginica  virginica  virginica  virginica
## [145] virginica  virginica  virginica  virginica  virginica  virginica
## Levels: setosa versicolor virginica
```

```
# Randomforest 는 앙상블(Ensemble) 학습을 사용한 모델
# 앙상블 학습은 주어진 데이터로부터 여러개의 모델을 학습한 다음,
# 예측 시 여러 모델의 예측 결과들을 종합해 정확도를 높이는 기법

# 랜덤 포레스트는 두가지 방법을 사용해 다양한 의사결정 나무를 만듬
# 첫번째, 데이터의 일부를 복원추출로 사용하여 의사결정나무 생성
# 두번째 노드 나누는 기준에 사용되는 변수를 일부만 사용

# 랜덤포레스트는 성능이 뛰어난 의사결정나무 하나로 모형을 예측하지 않고
# 여러개를 사용하여 예측하므로 과적합므이 문제가 피해간다.
```

```
if(!require(randomForest)) install.packages("randomForest"); library(randomFo
rest)
```

```
## Loading required package: randomForest
```

```
## Warning: package 'randomForest' was built under R version 3.4.4
```

```
## randomForest 4.6-14
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```r
rf.iris <- randomForest(Species~., data=iris, importance=TRUE)

rf.iris
```

```
##
## Call:
##  randomForest(formula = Species ~ ., data = iris, importance = TRUE)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 2
##
##         OOB estimate of  error rate: 4.67%
## Confusion matrix:
##            setosa versicolor virginica class.error
## setosa         50          0         0        0.00
## versicolor      0         47         3        0.06
## virginica       0          4        46        0.08
```

```r
plot(rf.iris) #적절한 ntress 를 판단할 수 있다.
```

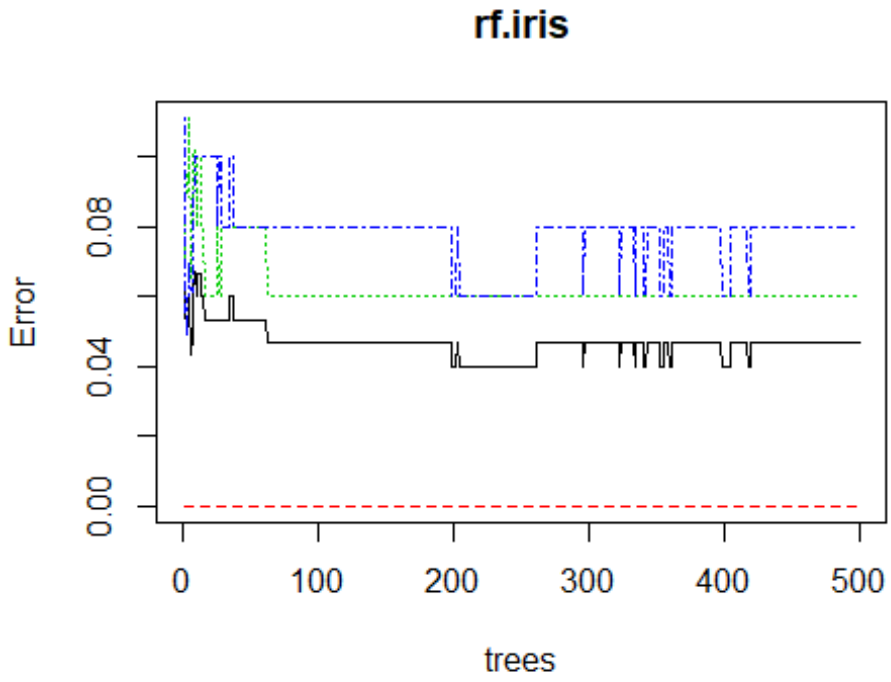


```r
importance(rf.iris) #변수별 중요도 확인
```

```
##                setosa versicolor virginica MeanDecreaseAccuracy
## Sepal.Length 6.316789   7.143148  8.090678             10.70338
## Sepal.Width  4.622851   1.462479  4.415429              5.00773
```

```
## Petal.Length 23.064071  32.965867 27.345715             33.95829
## Petal.Width  22.173873  31.523845 29.390400             33.38757
##              MeanDecreaseGini
## Sepal.Length         9.265806
## Sepal.Width          2.141824
## Petal.Length        43.651369
## Petal.Width         44.169060
```

```
varImpPlot(rf.iris)
```

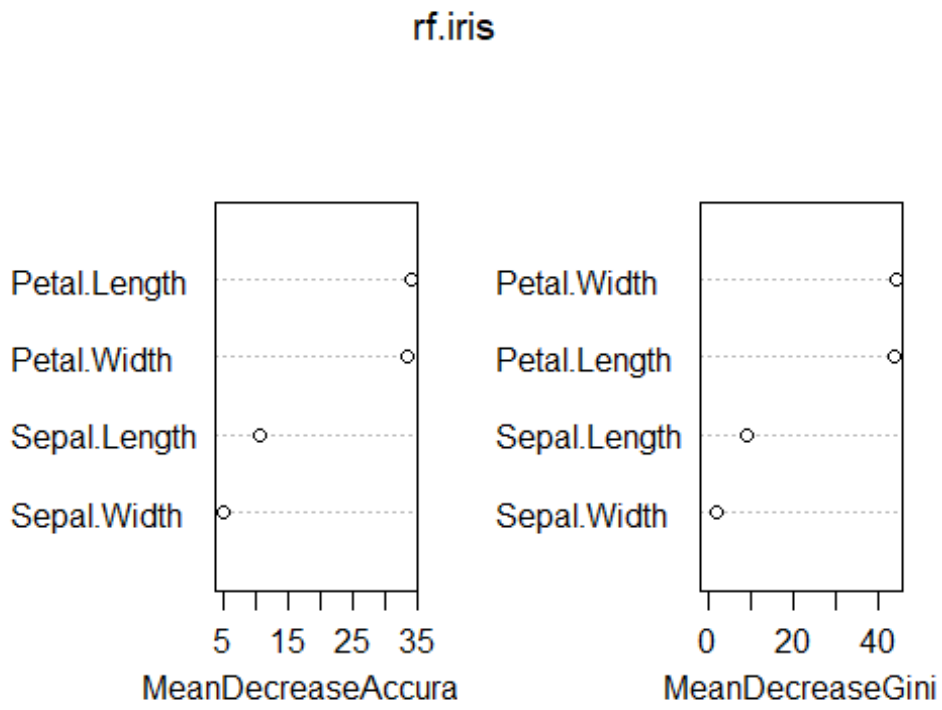


```
# 랜덤포레스트를 개선한 RRF (Regularized Random Forest)도 있음
# package(RRF)

# 랜덤포레스트 모형개선
# randomforest()함수에서는 나무개수, 고려할 변수 mtry 등의 파라메터가 있다.
# 기본적으로 자동자로 잘 부여되지만 모형 성능을 개선하고 싶다면 이 값을  조정할 수 있다.

grid <- expand.grid(ntree=c(10,100,200), mtry=c(2,3,4))
grid
```

```
##   ntree mtry
## 1    10    2
## 2   100    2
```

```
## 3   200    2
## 4    10    3
## 5   100    3
## 6   200    3
## 7    10    4
## 8   100    4
## 9   200    4
```

```
# 최적 조합을 찾기 위해 10 개로 분할된 데이터를 이용해보자.
```

```
if(!require(cvTools)) install.packages("cvTools"); library(cvTools)
```

```
## Loading required package: cvTools
```

```
## Warning: package 'cvTools' was built under R version 3.4.4
```

```
## Loading required package: lattice
```

```
## Loading required package: robustbase
```

```
## Warning: package 'robustbase' was built under R version 3.4.2
```

```
if(!require(foreach)) install.packages("foreach"); library(foreach)
```

```
## Loading required package: foreach
```

```
## Warning: package 'foreach' was built under R version 3.4.4
```

```
set.seed(3513)
K=10
R=3

cv <- cvFolds(nrow(iris), K=K, R=R)

grid <- expand.grid(ntree=c(10,100,200), mtry=c(3,4))

result <- foreach(g=1:nrow(grid), .combine=rbind) %do% {
  foreach(r=1:R, .combine = rbind) %do% {
    foreach(k=1:K, .combine=rbind) %do% {

      validation_idx <- cv$subsets[which(cv$which == k), r]

      train <- iris[-validation_idx,]
      validation <- iris[validation_idx,]

      m <- randomForest(Species~., data=train, ntree=grid[g, "ntree"],
                        mtry=grid[g,"mtry"])

      predicted <- predict(m, newdata=validation)
```

```
      precision <- sum(predicted == validation$Species) / length(predicted)
      return(data.frame(g=g, precision=precision))
    }
  }
}

result
```

```
##     g precision
## 1   1 1.0000000
## 2   1 1.0000000
## 3   1 0.9333333
## 4   1 1.0000000
## 5   1 0.9333333
## 6   1 0.9333333
## 7   1 1.0000000
## 8   1 0.8666667
## 9   1 1.0000000
## 10  1 0.9333333
## 11  1 0.8000000
## 12  1 0.9333333
## 13  1 0.9333333
## 14  1 0.8666667
## 15  1 1.0000000
## 16  1 1.0000000
## 17  1 0.9333333
## 18  1 1.0000000
## 19  1 1.0000000
## 20  1 0.9333333
## 21  1 0.9333333
## 22  1 0.8666667
## 23  1 0.9333333
## 24  1 1.0000000
## 25  1 0.9333333
## 26  1 0.9333333
## 27  1 1.0000000
## 28  1 0.9333333
## 29  1 1.0000000
## 30  1 0.9333333
## 31  2 1.0000000
## 32  2 0.9333333
## 33  2 0.9333333
## 34  2 1.0000000
## 35  2 0.9333333
## 36  2 0.9333333
## 37  2 1.0000000
## 38  2 0.8666667
## 39  2 1.0000000
## 40  2 0.9333333
```

```
## 41  2 0.8000000
## 42  2 0.9333333
## 43  2 0.9333333
## 44  2 0.9333333
## 45  2 1.0000000
## 46  2 1.0000000
## 47  2 0.9333333
## 48  2 1.0000000
## 49  2 1.0000000
## 50  2 0.9333333
## 51  2 0.9333333
## 52  2 0.8666667
## 53  2 0.9333333
## 54  2 1.0000000
## 55  2 1.0000000
## 56  2 0.9333333
## 57  2 1.0000000
## 58  2 0.9333333
## 59  2 1.0000000
## 60  2 0.9333333
## 61  3 1.0000000
## 62  3 0.9333333
## 63  3 0.9333333
## 64  3 1.0000000
## 65  3 0.9333333
## 66  3 0.9333333
## 67  3 1.0000000
## 68  3 0.8666667
## 69  3 1.0000000
## 70  3 0.9333333
## 71  3 0.8000000
## 72  3 0.9333333
## 73  3 0.9333333
## 74  3 0.8666667
## 75  3 1.0000000
## 76  3 1.0000000
## 77  3 0.9333333
## 78  3 1.0000000
## 79  3 1.0000000
## 80  3 0.9333333
## 81  3 0.9333333
## 82  3 0.8666667
## 83  3 0.9333333
## 84  3 1.0000000
## 85  3 1.0000000
## 86  3 0.9333333
## 87  3 1.0000000
## 88  3 0.9333333
## 89  3 1.0000000
```

```
## 90  3 0.9333333
## 91  4 1.0000000
## 92  4 1.0000000
## 93  4 0.9333333
## 94  4 1.0000000
## 95  4 0.9333333
## 96  4 0.9333333
## 97  4 1.0000000
## 98  4 0.8666667
## 99  4 1.0000000
## 100 4 0.8666667
## 101 4 0.7333333
## 102 4 0.9333333
## 103 4 0.9333333
## 104 4 1.0000000
## 105 4 1.0000000
## 106 4 1.0000000
## 107 4 0.8666667
## 108 4 1.0000000
## 109 4 1.0000000
## 110 4 0.9333333
## 111 4 0.9333333
## 112 4 0.9333333
## 113 4 0.9333333
## 114 4 1.0000000
## 115 4 1.0000000
## 116 4 0.9333333
## 117 4 1.0000000
## 118 4 0.9333333
## 119 4 1.0000000
## 120 4 0.9333333
## 121 5 1.0000000
## 122 5 0.9333333
## 123 5 0.9333333
## 124 5 1.0000000
## 125 5 0.9333333
## 126 5 0.9333333
## 127 5 1.0000000
## 128 5 0.8666667
## 129 5 1.0000000
## 130 5 0.9333333
## 131 5 0.8000000
## 132 5 0.9333333
## 133 5 0.9333333
## 134 5 0.8666667
## 135 5 1.0000000
## 136 5 1.0000000
## 137 5 0.9333333
## 138 5 1.0000000
```

```
## 139 5 1.0000000
## 140 5 0.9333333
## 141 5 0.9333333
## 142 5 0.8666667
## 143 5 0.9333333
## 144 5 1.0000000
## 145 5 1.0000000
## 146 5 0.9333333
## 147 5 1.0000000
## 148 5 0.9333333
## 149 5 1.0000000
## 150 5 0.9333333
## 151 6 1.0000000
## 152 6 0.9333333
## 153 6 0.9333333
## 154 6 1.0000000
## 155 6 0.9333333
## 156 6 0.9333333
## 157 6 1.0000000
## 158 6 0.8666667
## 159 6 1.0000000
## 160 6 0.9333333
## 161 6 0.8000000
## 162 6 0.9333333
## 163 6 0.9333333
## 164 6 0.8666667
## 165 6 1.0000000
## 166 6 1.0000000
## 167 6 0.9333333
## 168 6 1.0000000
## 169 6 1.0000000
## 170 6 0.9333333
## 171 6 0.9333333
## 172 6 0.9333333
## 173 6 0.9333333
## 174 6 1.0000000
## 175 6 1.0000000
## 176 6 0.9333333
## 177 6 1.0000000
## 178 6 0.9333333
## 179 6 1.0000000
## 180 6 0.9333333
```

```
if(!require(plyr)) install.packages("plyr"); library(plyr)
```

```
## Loading required package: plyr
```

```
##
## Attaching package: 'plyr'
```

```
## The following object is masked from 'package:modeltools':
##
##     empty

#grid 에 따른 결과를 살펴보자.
ddply(result, ~g, summarize, mean_precision=mean(precision))

##   g mean_precision
## 1 1      0.9488889
## 2 2      0.9511111
## 3 3      0.9488889
## 4 4      0.9511111
## 5 5      0.9488889
## 6 6      0.9511111
```